

Arquitetura Medalhão

DATA LAKEHOUSE

A **arquitetura medalhão** é um padrão de design de dados usado para organizar logicamente os dados do lakehouse, que visa melhorar de forma incremental e progressiva a estrutura e a qualidade dos dados à medida que fluem pelas três camadas da arquitetura (tabelas Bronze ⇒ Prata ⇒ Ouro).

As arquiteturas medalhão também são conhecidas como arquitetura “multi-hop”.



Arquitetura Medalhão

DATA LAKEHOUSE

ARQUITETURA MEDALHÃO



LANDING



BRONZE



SILVER



GOLD

Arquitetura Medalhão

LANDING

- É uma camada provisória, responsável pela primeira ingestão dos dados no data lake.
- Formato original dos arquivos em seus sistema de origens (CSV, JSON, XML, etc).
- Geralmente não guarda histórico (mas pode ser utilizada como histórico).
- Normalmente usada como backup para recriar um conjunto de dados.
- Ingestão full ou incremental.
- Utilizada apenas por engenheiros de dados.




LANDING

Arquitetura Medalhão

BRONZE

- Cópia da camada anterior (landing).
- Mantem histórico completo dos dados brutos (ainda não processados).
- Formato delta (ACID, metadados, etc).
- Dados imutáveis (apenas leitura).
- Normalmente particionados por data (ano, mês, dia).
- Podem incluir metadados adicionais (colunas), como nomes de arquivos de origem, data e hora em que os dados foram processados, etc.
- Utilizada apenas por engenheiros de dados.



Arquitetura Medalhão

SILVER

- Formato delta (ACID, metadados, etc).
- Incremental. Normalmente usa técnicas de SCD 2.
- Geralmente alinhados e organizados com o sistema de origem.
- Pode ocorrer pequenas agregações* e união de tabelas do mesmo assunto.
- Utilizada por engenheiros de dados e engenheiros de ML e IA (consultas Ad Hoc).
- Padronização e regras de qualidade (nomenclatura dos campos - ex: inglês para português, minúsculo x maiúsculo, retirada de abreviações - cd_cliente = CODIGO_CLIENTE).
- Remoção de dados duplicados, trata dados ausentes, padroniza vazios ou inválidos.
- Podem incluir metadados adicionais (colunas), como nomes de arquivos de origem, data e hora em que os dados foram processados, etc.



SILVER

Arquitetura Medalhão

GOLD

- Formato delta (ACID, metadados, etc).
- Dados transformados de acordo com as regras de negócio para consumo ou casos de uso.
- Modelo de dados otimizado para leitura (Dimensional, OBT, etc).
- Controle de dados históricos são aplicados apenas para o conjunto de dados dos casos de uso de acordo com suas regras, tendo em mente que esta camada pode ser uma seleção ou agregação de dados encontrados na camada Prata.
- Os dados são altamente governados e bem documentados.



GOLD

Arquitetura Medalhão

DATA LAKEHOUSE

ARQUITETURA MEDALHÃO



- Batch
- Formato bruto
- Camada ingestão
- Provisório

LANDING



- Cópia da camada landing
- Histórico
- Formato delta

BRONZE



- Limpeza, tratamento, filtro, data quality
- Pequenas agregações e desnormalizações
- Formato delta

SILVER



- Regras de negócio
- Modelo dimensional/OBT
- Formato delta

GOLD

Atividade Prática

ARQUITETURA MEDALHAO COM DATABRICKS COMMUNITY

1. Logar no Databricks Free Edition - <https://www.databricks.com/learn/free-edition>
2. Importar os notebooks no workspace;
3. Importar os arquivos CSV no volume dados do schema landing/dados e movê-los para o bronze, silver e gold no modelo dimensional através dos notebooks.



Atividade Prática – Trabalho 3 (1 ponto)

LAKEHOUSE COM DATABRICKS FREE EDITION E ARQUITETURA MEDALHAO


OBJETIVO: Construir um pipeline de dados no Databricks implementando a arquitetura Medalhão (experiência PaaS).

(Landing -> Bronze -> Silver -> Gold) com Jobs & Pipeline.



Atividade Prática – Trabalho 3 (1 ponto)

LAKEHOUSE COM DATABRICKS FREE EDITION E ARQUITETURA MEDALHAO



IMPORTANTE:

- Este trabalho deve ser feito em NOVO REPOSITÓRIO no GitHub (cada trabalho com seu repositório separado).
- Utilizem os notebooks disponibilizados em aula como modelo/exemplo para desenvolvimento do trabalho 3.
- Não esqueçam da organização de pastas do GITHUB, README e MKDOCS para este novo repositório.



ENTREGA EM
12/05

LEGENDA DAS CAMADAS (MEDALHAO)

LANDING

Dados brutos extraídos da origem (CSV/JSON)

BRONZE

Dados brutos armazenados (Delta Lake)

SILVER

Dados tratados e confiáveis (Delta Lake)

GOLD

Dados modelados para análise (Ralph Kimball)



TECNOLOGIAS

- Databricks Free Edition
- Delta Lake
- CSV / JSON
- Jobs & Pipelines

Atividade Prática – Trabalho 3 (1 ponto)

LAKEHOUSE COM DATABRICKS FREE EDITION E ARQUITETURA MEDALHAO

1. O trabalho 3 é um complemento do trabalho 1 e 2, onde vocês deverão implementar a extração dos dados de todas as tabelas de um banco de dados (relacional ou não relacional - livre escolha) e gravar em um SCHEMA no DATABRICKS chamado LANDING/DADOS no formato CSV (para relacional) e JSON (para não relacional).
2. Após a extração, vocês deverão ler os arquivos CSV ou JSON do SCHEMA LANDING/DADOS e gravar no formato DELTA LAKE em um novo SCHEMA chamado BRONZE.
3. Depois vocês deverão ler todos os dados do SCHEMA BRONZE, aplicar “*Data Quality*” e gravar no SCHEMA SILVER.
4. Por fim vocês precisarão ler os dados do SCHEMA SILVER e alimentar as tabelas dimensionais (Ralph Kimball) no SCHEMA GOLD.

Atividade Prática – Trabalho 2 (1 ponto)

LAKEHOUSE COM DATABRICKS FREE EDITION E ARQUITETURA MEDALHAO

5. Todas as execuções dos notebooks deverão estar encadeadas através de uma JOB (Jobs & Pipelines), onde cada etapa é executada sequencialmente.

IMPORTANTE:

- Apesar do trabalho 3 ser um complemento do trabalho 1 e 2, o trabalho deverá ser feito em NOVO REPOSITÓRIO NO GITHUB, ou seja, cada trabalho deverá ter o seu repositório no GitHub separado.
- Utilizem os notebooks disponibilizados em aula como modelo/exemplo para desenvolvimento do trabalho 3.
- Não esqueçam da organização de pastas do GITHUB, README e MKDOCS para este novo repositório.

ENTREGA EM 12/05