

Atividade Prática – Trabalho 3 (1 ponto)

LAKEHOUSE COM DATABRICKS FREE EDITION E ARQUITETURA MEDALHAO


OBJETIVO: Construir um pipeline de dados no Databricks implementando a arquitetura Medalhão (experiência PaaS).

(Landing -> Bronze -> Silver -> Gold) com Jobs & Pipeline.



Atividade Prática – Trabalho 3 (1 ponto)

LAKEHOUSE COM DATABRICKS FREE EDITION E ARQUITETURA MEDALHAO



IMPORTANTE:

- Este trabalho deve ser feito em NOVO REPOSITÓRIO no GitHub (cada trabalho com seu repositório separado).
- Utilizem os notebooks disponibilizados em aula como modelo/exemplo para desenvolvimento do trabalho 3.
- Não esqueçam da organização de pastas do GITHUB, README e MKDOCS para este novo repositório.



ENTREGA EM
12/05

LEGENDA DAS CAMADAS (MEDALHAO)

LANDING

Dados brutos extraídos da origem (CSV/JSON)

BRONZE

Dados brutos armazenados (Delta Lake)

SILVER

Dados tratados e confiáveis (Delta Lake)

GOLD

Dados modelados para análise (Ralph Kimball)



TECNOLOGIAS

- Databricks Free Edition
- Delta Lake
- CSV / JSON
- Jobs & Pipelines

Atividade Prática – Trabalho 3 (1 ponto)

LAKEHOUSE COM DATABRICKS FREE EDITION E ARQUITETURA MEDALHAO

1. O trabalho 3 é um complemento do trabalho 1 e 2, onde vocês deverão implementar a extração dos dados de todas as tabelas de um banco de dados (relacional ou não relacional - livre escolha) e gravar em um SCHEMA no DATABRICKS chamado LANDING/DADOS no formato CSV (para relacional) e JSON (para não relacional).
2. Após a extração, vocês deverão ler os arquivos CSV ou JSON do SCHEMA LANDING/DADOS e gravar no formato DELTA LAKE em um novo SCHEMA chamado BRONZE.
3. Depois vocês deverão ler todos os dados do SCHEMA BRONZE, aplicar *“Data Quality”* e gravar no SCHEMA SILVER.
4. Por fim vocês precisarão ler os dados do SCHEMA SILVER e alimentar as tabelas dimensionais (Ralph Kimball) no SCHEMA GOLD.

Atividade Prática – Trabalho 2 (1 ponto)

LAKEHOUSE COM DATABRICKS FREE EDITION E ARQUITETURA MEDALHAO

5. Todas as execuções dos notebooks deverão estar encadeadas através de uma JOB (Jobs & Pipelines), onde cada etapa é executada sequencialmente.

IMPORTANTE:

- Apesar do trabalho 3 ser um complemento do trabalho 1 e 2, o trabalho deverá ser feito em NOVO REPOSITÓRIO NO GITHUB, ou seja, cada trabalho deverá ter o seu repositório no GitHub separado.
- Utilizem os notebooks disponibilizados em aula como modelo/exemplo para desenvolvimento do trabalho 3.
- Não esqueçam da organização de pastas do GITHUB, README e MKDOCS para este novo repositório.

ENTREGA EM 12/05